

Libro de códigos

Establecimientos educativos de nivel diversificado de Guatemala.

Metadato	Valor
Fuente	Portal MINEDUC — https://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/
Fecha de extracción	2026-07-16
Registros (crudo)	11,867
Variables (crudo)	17 (+1 derivada, ver §3)
Nivel	DIVERSIFICADO (filtro de la descarga)
Cobertura	23 departamentos
Registros (limpio)	11,867 (sin cambio; no se eliminaron filas)
Variables (limpio)	18 (17 + TELEFONO_2)
Versión del conjunto limpio	1.0 — output/establecimientos_limpios.csv
Fecha de generación del limpio	2026-07-20

Todas las variables se extraen como texto de una tabla HTML. El "tipo" indica el tipo que le corresponde al dato, no el de almacenamiento.

1. Definición de variables

Variable	Descripción	Tipo	Dominio / valores posibles
CODIGO	Código único del establecimiento	Identificador	Patrón dd-dd-dddd-dd; los 2 primeros dígitos son el departamento
DISTRITO	Código del distrito escolar	Identificador	Patrón dd-ddd; numeración propia, no codifica el departamento

DEPARTAMENTO	Departamento del establecimiento	Categorico	23 valores del catálogo oficial (el portal separa CIUDAD CAPITAL de GUATEMALA)
MUNICIPIO	Municipio del establecimiento	Categorico	Catálogo oficial por departamento (profiling/catalogo_municipios.csv); válido solo dentro de su departamento
ESTABLECIMIENTO	Nombre del establecimiento	Texto libre	Nombre propio; conserva ortografía y tildes
DIRECCION	Dirección física	Texto libre	—
TELEFONO	Teléfono principal	Numérico	8 dígitos (numeración nacional)
SUPERVISOR	Nombre del supervisor	Texto libre	Nombre de persona
DIRECTOR	Nombre del director	Texto libre	Nombre de persona
NIVEL	Nivel educativo	Categorico	DIVERSIFICADO
SECTOR	Sector administrativo	Categorico	PRIVADO, OFICIAL, COOPERATIVA, MUNICIPAL
AREA	Área geográfica	Categorico	URBANA, RURAL, SIN ESPECIFICAR
STATUS	Estado del establecimiento	Categorico	ABIERTA, CERRADA TEMPORALMENTE, CERRADA DEFINITIVAMENTE, TEMPORAL TITULOS, TEMPORAL NOMBRAMIENTO
MODALIDAD	Modalidad lingüística	Categorico	MONOLINGUE, BILINGUE
JORNADA	Jornada	Categorico	DOBLE, VESPERTINA, MATUTINA, SIN JORNADA, NOCTURNA, INTERMEDIA
PLAN	Plan de estudios	Categorico	DIARIO(REGULAR), FIN DE SEMANA, SEMIPRESENCIAL (y variantes), A DISTANCIA, VIRTUAL A DISTANCIA, SABATINO, DOMINICAL, MIXTO, IRREGULAR, INTERCALADO
DEPARTAMENTAL	Dirección departamental del MINEDUC	Categorico	26 valores (GUATEMALA se divide en 4, QUICHÉ en 2)

2. Calidad y tratamiento por variable

Faltantes sobre 11,867 (crudo). Registros afectados = filas que cambió la limpieza aplicada por `main.py` (detalle en `output/transformaciones.csv`).

Variable	Faltantes	Problemas detectados	Tratamiento aplicado	Registros afectados
CODIGO	0	Ninguno	Validar patrón; sin cambios	0
DISTRITO	532 (4.48%)	Invisibles, puntuación de borde	Normalizar faltantes	532
DEPARTAMENTO	0	Ninguno	Sin cambios; verificado contra CODIGO	0
MUNICIPIO	0	Ninguno	Sin cambios; verificado par con DEPARTAMENTO	0
ESTABLECIMIENTO	5 (0.04%)	Categorías duplicadas (2130), espacios (1395), puntuación (397), typos (218)	Normalizar forma (espacios, puntuación). Ortografía/typos: revisión manual	1,797
DIRECCION	76 (0.64%)	Categorías duplicadas (853), espacios (485), puntuación (121)	Normalizar forma + mayúsculas + faltantes	705
TELEFONO	946 (7.97%)	Fuera de formato (251), multivalor (183)	Solo dígitos; 2º número → TELEFONO_2 (§3)	1,089
SUPERVISOR	535 (4.51%)	Categorías duplicadas (1198), espacios (133)	Normalizar forma + faltantes	700
DIRECTOR	1,732 (14.6%)	Centinelas (414), espacios (1109), categorías duplicadas (244)	Normalizar forma + faltantes; mojibake a revisión manual	3,235
NIVEL	0	Ninguno	Sin cambios	0
SECTOR	0	Ninguno	Sin cambios	0
AREA	0	Ninguno	Sin cambios	0
STATUS	0	Ninguno	Sin cambios	0
MODALIDAD	0	Ninguno	Sin cambios	0

JORNADA	0	Ninguno	Sin cambios	0
PLAN	0	Ninguno	Sin cambios	0
DEPARTAMENTAL	0	Ninguno	Sin cambios	0

Total de registros afectados: 8,058. Ningún registro fue eliminado. Detalle de faltantes en `summary_tables/resumen_general.csv`; problemas por valor en `profiling/valores_problematicos.csv`; transformaciones en `output/transformaciones.csv`.

3. Variables derivadas

Variable	Origen	Descripción
TELEFONO_2	TELEFONO	Segundo número, cuando la celda traía más de uno (183 casos). Se separa para no perder el dato. Vacío si solo había un número

4. Reproducibilidad

El conjunto limpio se regenera con `python -m src.main`, que aplica las reglas de `limpieza.py` sobre el crudo y escribe `output/establecimientos_limpios.csv`. El informe de comparación antes/después está en `output/informe_calidad.md`.